PromptShield BR - Fase 3

Challenge Intelliway | Detecção de Prompt Injection em PT-BR

Etapa do projeto: Sprint 1 - Proposta técnica documentada

Grupo: Grupo 2

Integrantes e respectivos RMs:

Cláudio Sartori - RM 567194

Douglas Rafael do Amaral - RM 566740

Pedro Alves da Silva - RM 567029

William A. C. Vasconcelos - RM 567096

Resumo da entrega

A entrega da Fase 3 apresenta o planejamento da Sprint 1 do Challenge Intelliway, voltado à segurança de agentes de inteligência artificial que consomem conteúdo externo. O PromptShield BR propõe detectar tentativas de prompt injection em português brasileiro por meio de um serviço independente, consumido por API. A solução planejada separa classificação, score de risco e decisões ALLOW, REVIEW ou BLOCK, mantendo a inferência independente de LLM generativo. A documentação reúne modelo de ameaças, catálogo de histórias propostas, estratégia de dataset PT-BR com hard negatives e prevenção de data leakage, baselines Regex e TF-IDF e avaliação futura de DeBERTa. Também descreve arquitetura com OCR e RAG, registros auditáveis, wireframes do portal administrativo, revisão humana, governança e roadmap. Esta Sprint é exclusivamente documental: não apresenta implementação funcional nem métricas experimentais.

Componentes preparados

Componente	Conteúdo preparado
Análise do problema	Modelo de ameaças diretas e indiretas; ativos, perfis e riscos.
User Stories	15 histórias propostas: 8 P0, 5 P1 e 2 P2; critérios e dependências.
Dataset PT-BR	Fontes candidatas, licenças pendentes, rotulagem, hard negatives e splits.
Baselines	Planejamento de regras/Regex e TF-IDF com classificador linear.
Modelo profundo	Proposta de avaliação DeBERTa em PT-BR e fine-tuning; LoRA como opção.
Arquitetura	Serviço independente: API, motor, OCR, RAG, registros e portal.
Contrato da API	Exemplos JSON, source_type, score, decisões e versões.
Portal administrativo	Wireframes, navegação, histórico e revisão humana aditiva.
Governança	Propostas de LGPD, minimização, riscos, auditoria e versionamento.
Roadmap	Sprints futuras, gates de dados/modelos e validação oficial pendente.

Repositório GitHub

https://github.com/amaralthedoug/promptshield-br

Repositório público, com endereço e visibilidade verificados.

Observação acadêmica

A Fase 3 corresponde à entrega atual do curso e apresenta a Sprint 1 do Challenge Intelliway como proposta técnica documentada, sem implementação funcional ou métricas experimentais. O catálogo contém **User Stories propostas pelo grupo - sujeitas à validação perante a especificação oficial da Intelliway**; não comprova cobertura integral das P0 oficiais.